

Análisis exploratorio de una cartera colombiana de créditos de consumo

Mateo Monsalve Valencia
Ingeniería de Sistemas e Informática
Ingeniería en Ciencias de Datos
Universidad Pontificia Bolivariana
Medellin, Colombia
mateo.monsalvev@upb.edu.co

I. INTRODUCCIÓN

Se analizó un extracto de 10.763 créditos de consumo otorgados en Colombia, el dataset cuenta con 23 columnas y una variable binaria que indica si el crédito se pagó a tiempo. Este dataset no viene acompañado de diccionario de datos, así que el primer trabajo fue establecer qué mide cada columna, cuáles son confiables y cuáles no significan lo que su nombre sugiere.

El análisis siguió seis pasos. Primero, caracterizar cada variable y revisar cómo se distribuye. Segundo, limpiar el extracto y validarlo contra reglas de rango, con la particularidad de que esas reglas se contrastaron con valores publicados del mercado colombiano en lugar de fijarse a ojo. Tercero, comparar tasas de incumplimiento entre grupos. Cuarto, medir la asociación de cada variable con el resultado usando dos medidas en paralelo, una lineal y una de rangos, porque en este conjunto de datos discrepan de forma sistemática. Quinto, construir variables derivadas y ordenarlas por su relación con el objetivo. Y finalmente, depurar los hallazgos hasta el conjunto que se presenta aquí.

II. DATOS Y PREPARACIÓN

Entre las operaciones realizadas para preparar el dataset existen 3 operaciones de alta importancia, puesto que pueden afectar la interpretación de los resultados posteriores.

En la variable `tendencia_ingresos` se encontraron 58 filas que almacenaban un número en lugar de una etiqueta, se observa que este comportamiento se trata de deltas de ingreso que se filtraron a la columna de etiqueta. Puesto que en los demás registros se observaba que la columna contenía las etiquetas *Creciente*, *Estable* y *Decreciente*, se decidió mantener la magnitud en una columna aparte y recuperar la etiqueta a partir de su signo.

La variable `puntaje_datacredito` contenía 145 filas con valor cero, lo cual no es un score válido, en su lugar, se observa que este valor se usa como un centinela de «sin calificar», por lo que se decidió convertir estos valores a nulos, puesto que su valor no representa realmente un score crediticio.

Tras analizar documentación y observar las magnitudes de las columnas de saldo, se decidió reescalar estas variables, puesto que se observó que los saldos estaban denominados en

Tabla I

REGLAS DE RANGO APLICADAS. *Observado* SON LOS RANGOS PRESENTES EN EL ARCHIVO AL MOMENTO DE LA CARGA. *Regla* SON LOS INTERVALOS QUE SE ACEPTAN COMO VÁLIDOS CON BASE EN LA LÓGICA DE NEGOCIO. *OOR* SON LAS FILAS QUE LA REGLA RECHAZA.

Variable	Observado	Regla	OOR
salario_cliente	0 – 22.000 M	$[10^6, 10^8]$	186
edad_cliente	19 – 123	$[18, 90]$	150
total_otros_prestamos	0 – 6.788 M	$[0, 5 \times 10^8]$	22
puntaje_datacredito	–7 – 999	$[150, 950]$	8
plazo_meses	2 – 90	$[1, 60]$	1
cant_creditosvigentes	0 – 62	$[0, 40]$	1

miles de pesos, lo cual no es consistente con el resto de las variables y puede afectar la interpretación de los resultados y futuros uso en inferencia de modelos. El análisis detallado de esta decisión se encuentra en la Sección VI.

También se observó que los datos faltantes en las columnas `promedio_ingresos_datacredito` y `tendencia_ingresos` no son aleatorios, sino que se presentan en bloques. En concreto, 2.930 filas, es decir el 27 % del extracto, pierden ambas columnas a la vez y por lo tanto no tienen registro de ingreso en DataCrédito Experian, mientras que otras 156 filas pierden de una sola vez todo el bloque de saldos. La ausencia de dato resulta informativa por sí misma, puesto que los créditos sin registro de ingreso en el DataCrédito Experian incumplen al 5,73 % frente a 4,38 % cuando el registro está presente, por lo que se decidió conservarla como variable indicadora en lugar de imputarla.

En la Tabla I se observan los valores encontrados en variables numéricas, y las reglas de rango que se aplicaron para validar los datos. La columna *OOR* indica la cantidad de filas que incumplen la regla de rango aplicada. Los rangos fueron verificados contra referencias externas cuando fuese posible, y en cada caso la fuente se cita junto al valor de referencia correspondiente.

III. POTENCIAL FUGA DE LA VARIABLE OBJETIVO EN *puntaje*

La columna `puntaje` es un score interno en una escala nominal de 0 a 100. El principal hallazgo es la correlación

(Correlación punto-biserial) que presenta con la variable objetivo de $r_{pb} = 0,923$, lo cual es extremadamente alta.

Este resultado puede indicar dos principales resultados, el primero y más probable es que la variable puntaje contiene información sobre el resultado que no debería estar disponible en el momento de originar el crédito, por lo que sería considerado una fuga de información. El segundo, es que la variable puntaje es casi un aproximador perfecto de la variable objetivo, lo cual es poco probable y no se considera en este análisis. Pero finalmente, determinar cuál de los 2 outcomes representa depende de analizar el origen y cómo se genera la variable puntaje, y si esta se genera antes o después de conocer el resultado del crédito.

Como se observa en la gráfica, se puede observar que todas las observaciones con un $\text{puntaje} \leq 62,67$ incumplen y por su parte, todas las observaciones con un $\text{puntaje} \geq 63,81$ pagan a tiempo.

Además, se observa que el 87 % de la cartera se encuentra en un único valor de puntaje de 95,227787. Esto refuerza la lectura anterior de la correlación punto-biserial, y sugiere la existencia de una fuga de información, puesto que el score interno es capaz de separar perfectamente los clientes que incumplen de los que pagan a tiempo. Y en caso de que no exista una fuga, y los demás datos sigan un comportamiento igual al de la presente muestra, cualquier modelo basado en datos tendría un comportamiento igual o inferior al uso de la regla

$$\text{puntaje} \leq 62,67 \Rightarrow \text{Pago_atiempo} = 0$$

Al consultar el contexto regulatorio, se concreta el diagnóstico. La Superintendencia Financiera de Colombia exige a las entidades vigiladas evaluar el riesgo de crédito tanto en la originación como a lo largo de la vida del crédito, de modo que una bodega de datos almacena de forma rutinaria más de un score por préstamo [4], [5]. En los modelos colombianos de *score de comportamiento* el cliente se marca como adverso al alcanzar mora superior a 60 o 90 días dentro de una ventana de observación de 12 meses, que es el mismo evento que codifica la variable objetivo.

IV. EL SCORE DEL DATACRÉDITO EXPERIAN

El dataset contiene un segundo score, del cual sí se puede estimar con alta confianza que proviene de una fuente externa: $\text{puntaje_datacredito}$, que corresponde al score de DataCrédito Experian en la escala oficial de 150 a 950 [6]. Compararlo contra puntaje es la forma más clara de caracterizar cómo se ve una fuga y cómo se ve un score que no la tiene.

La distribución es unimodal, con asimetría negativa de $-1,30$ y concentrada en el tope de la escala, con mediana 792 y rango intercuartílico entre 758 y 826. Se encontraron ocho valores por fuera de la escala oficial, entre ellos -7 y 999, los cuales no corresponden a clientes extremos sino a valores imposibles, puesto que la escala no admite esos números. Una mediana de 792 indica que el originador ya

filtra potencialmente con dureza por el puntaje de DataCrédito Experian, lo cual condiciona la interpretación de todas las correlaciones débiles que se reportan más adelante, puesto que son en parte consecuencia de una originación efectiva y no evidencia de que la información de DataCrédito Experian sea poco informativa.

En la Fig. 2 se observa esa misma distribución separada por resultado, con la misma codificación de la Fig. 1 para que ambas puedan leerse una contra otra. El resultado es el opuesto: mientras que en puntaje las dos clases no se tocan en ningún punto, aquí se solapan casi por completo, puesto que los créditos que incumplen se reparten entre 287 y 922 y el 99,7 % de los créditos calificados cae dentro de ese rango. La distribución de los que incumplen está desplazada hacia la izquierda, que es de donde proviene la correlación de rangos reportada, pero está contenida dentro de la de los que pagan a tiempo y no separada de ella, que es como debe verse un score que estima riesgo sin conocer el resultado.

En la Fig. 3 se observa el comportamiento que importa. La tasa de incumplimiento cae de forma monótona por segmento de score, desde 70,0 % por debajo de 500 hasta 3,7 % en el segmento de 750 a 950, y la correlación de rangos con la variable objetivo es $\rho = +0,091$ con $p = 6 \times 10^{-21}$, es decir estadísticamente sólida pero modesta en magnitud.

El contraste con la sección anterior, este puntaje es el realmente útil, puesto que generaliza más allá de este conjunto de datos. Un score que predice un resultado produce un gradiente a lo largo de su rango, mientras que un score que ya conoce el resultado produce un muro.

Finalmente, se enfrentaron los dos scores en un mismo plano, como se observa en la Fig. 4. La recta punteada marca la referencia esperada, es decir dónde caerían los clientes si los dos instrumentos ordenaran el mismo riesgo y cada uno recorriera su escala declarada de extremo a extremo, de 150 a 950 la de DataCrédito Experian y de 0 a 100 la interna. Se decidió anclar esa recta en las escalas declaradas y no en la muestra, de modo que funcione como referencia y no como un ajuste a los datos.

Ningún tramo de la nube sigue esa recta. La correlación de rangos entre ambos scores es apenas $\rho = 0,118$ sobre las 10.612 filas que traen los dos valores, y lo que se observa son dos bloques superpuestos sobre el mismo eje horizontal, puesto que la línea del valor centinela recorre todo el rango de DataCrédito Experian y la nube inferior ocupa ese mismo rango. Entre los 1.777 clientes con score de DataCrédito Experian entre 790 y 810, es decir con prácticamente el mismo riesgo según DataCrédito Experian, esto demuestra que puntaje no discrimina entre ellos y que su pertenencia a uno u otro bloque no queda explicada por el score de DataCrédito Experian. La conclusión es que puntaje no es un score de riesgo sino un instrumento de decisión que ya conoce el resultado.




Figura 1. Distribución de `puntaje` separada por resultado, en escala logarítmica de conteo. La franja sombreada entre 62,67 y 63,81 no contiene ningún crédito de ninguna clase, así que cualquier umbral dentro de ella reproduce la etiqueta de forma perfecta. La columna además toma valores negativos, contra su escala nominal de 0 a 100, en 135 filas.




Figura 2. Distribución de `puntaje_datacredito` separada por resultado, en escala logarítmica de conteo y con la misma codificación de la Fig. 1. Las dos clases se solapan en casi todo el rango, a diferencia de lo que ocurre con `puntaje`.

V. DIFERENCIA ENTRE RELACIONES LINEALES Y MONOTÓNICAS EN LAS VARIABLES

Analizar las variables candidatas únicamente con la correlación de Pearson habría eliminado de la consideración la mayor parte de este conjunto de datos. Al ordenar los pares de variables según la diferencia $|\rho| - |r|$ entre los coeficientes de Spearman [7] y de Pearson, once de las doce diferencias

más grandes comparten la misma forma: una correlación de rangos entre 0,29 y 0,45 frente a una correlación lineal indistinguible de cero, y en cuatro casos ligeramente negativa. El par restante, `saldo_total` $\times$ `saldo_principal`, es fuerte bajo ambas medidas y aparece en la figura únicamente como contraste.

La Tabla II lista las tres mayores diferencias entre relaciones




Figura 3. Tasa de incumplimiento por segmento del score de DataCrédito Experian. El gradiente es monótono. Las barras rayadas se apoyan en menos de 50 créditos. Los clientes sin score de DataCrédito Experian incumplen al 7,3 %, por encima de la tasa base, pero con 151 créditos esa diferencia no es significativa (χ^2 , $p = 0,20$).

Tabla II
LAS TRES MAYORES DIFERENCIAS ENTRE SPEARMAN Y PEARSON ENTRE RELACIONES DISTINTAS.

Par de variables	r	ρ	Dif.
salario_cliente × saldo_total	0,005	0,445	0,441
total_otros_prestamos × saldo_total	0,083	0,444	0,361
salario_cliente × cuota_pactada	0,052	0,393	0,341

distintas. El orden literal ubica a `salario_cliente × saldo_principal` en el segundo lugar, pero `saldo_total y saldo_principal` correlacionan en $\rho = 0,946$ y son exactamente iguales en el 84 % de las filas —la diferencia es interés causado—, de manera que reportar ambos sería presentar la misma relación dos veces.

El desacuerdo también corre en sentido contrario, y ese caso también es diagnóstico. El par `puntaje × Pago_atiempo` tiene $r = 0,923$ pero $\rho = 0,639$, la mayor diferencia negativa de la matriz. Como el objetivo es dicotómico, aquí r es la correlación punto-biserial y ρ su análogo sobre rangos; ambos coeficientes son válidos y lo que cambia entre ellos no es la legitimidad sino qué parte de la variable observan.

VI. UNA COLUMNA QUE NO SIGNIFICA LO QUE DICE SU NOMBRE

El error documentado en esta sección no aparece como valor faltante ni como violación de rango. Afecta silenciosamente cualquier modelo construido sobre él, y se detectó comparando las magnitudes de la columna contra valores de referencia publicados para Colombia, y no mediante alguna verificación interna de consistencia. Puesto que los valores son internamente consistentes, la única forma de detectar el error es comparando contra rangos esperados desde fuentes externas.

VI-A. Los saldos del DataCrédito están denominados en miles

La columna `saldo_total` tiene mediana 16.178 frente a un salario declarado mediano de 3 millones de pesos. Léida

Tabla III
CANTIDADES DE DATACRÉDITO EXPERIAN ANTES Y DESPUÉS DE LA CORRECCIÓN DE UNIDADES. ABIERTAS.

Cantidad	Como viene	Corregida
Deuda total mediana en DataCrédito	16.178 COP	16,2 M COP
como múltiplo del salario mensual	$0,005 \times$	$5,4 \times$
Saldo mediano por cuenta abierta	3.305 COP	3,3 M COP
Mora mediana cuando está presente	236 COP	236.000 COP

como pesos, el cliente típico, que tiene cinco obligaciones abiertas, debería medio por ciento del ingreso de un mes. De forma similar, `saldo_mora` tiene mediana 236 entre las filas no nulas.

La prueba es interna y no depende de ninguna referencia externa. La Fig. 5 aísla a los 402 clientes que tienen exactamente una obligación abierta y saldo positivo (de 636 con una sola obligación, el resto tiene saldo cero y la razón queda indefinida). Para esos clientes todo el saldo de DataCrédito Experian tiene que corresponder a un único crédito, y el monto que se les prestó es conocido. Tal como viene el archivo, la razón `capital_prestado/saldo_total` tiene mediana 1.338. Dividida por mil queda en 1,34: el saldo vigente es el 74,7 % del principal original, que es justamente lo que debe verse en un crédito parcialmente amortizado. Léida en pesos la misma razón daría un saldo del 0,07 % del principal, que ninguna lectura plausible produce.

En Colombia los saldos de cartera se reportan convencionalmente en miles de pesos, así que esto es una convención, pero nada en el archivo lo declara. La Tabla III muestra cómo cambian las cantidades. La corrección también reparó un defecto introducido durante la construcción de variables: una razón que dividía un saldo denominado en miles por un capital denominado en pesos estaba equivocada por un factor de mil. Como el error era un factor constante, nunca afectó un ordenamiento basado en rangos ni un modelo de árboles, pero los valores carecían de sentido y cualquier modelo lineal o afirmación de negocio que los citara habría sido incorrecta.

VI-B. La carga financiera no predice el incumplimiento

Los originadores colombianos acostumbran limitar la carga financiera entre el 30 % y el 40 % del ingreso mensual [12]. El cliente mediano de esta cartera se ubica en 42 %, justo por fuera de esa banda el día en que se otorgó el crédito. La Fig. 6 muestra el resultado que importa: la carga financiera no separa a los clientes que incumplen. La banda nominalmente ideal, por debajo del 30 %, tiene la tasa de incumplimiento más alta, de 6,0 %, y la banda por encima del 60 % la segunda más baja, de 3,9 %.

La explicación más plausible es la selección. El originador ya evalúa capacidad de pago, de modo que lo que llega al conjunto de datos no es una muestra libre de solicitantes, y los clientes que declaran poca deuda adicional pueden ser sencillamente aquellos con vidas financieras más delgadas y menos verificables. Sea cual sea la causa, las razones de capacidad de pago son las cantidades correctas para calcular




Figura 4. puntaje contra puntaje_datacredito, separados por resultado. La recta punteada es la relación que cabría esperar si ambos scores ordenaran el mismo riesgo sobre sus escalas declaradas. La línea horizontal superior es el valor centinela, que abarca todo el rango del score de DataCrédito Experian, y la nube inferior ocupa ese mismo rango: la pertenencia a uno u otro bloque no queda explicada por el score de DataCrédito Experian.




Figura 5. Razón entre `capital_prestado` y `saldo_total` para los 402 clientes con exactamente una obligación abierta y saldo positivo, antes y después de dividir el saldo de DataCrédito Experian por mil. La línea punteada marca la igualdad con el crédito recién otorgado.




Figura 6. Tasa de incumplimiento por banda de carga financiera. El orden convencional aparece invertido: la banda nominalmente más segura es la que peor se comporta.

y ahora son dimensionalmente correctas, pero no son donde está la señal en esta cartera, y a quien espere lo contrario hay que decírselo de forma directa.

VII. PRINCIPALES SEÑALES

VII-A. Mora ya reportada en DataCrédito Experian

La principal regla del conjunto de datos no requiere modelo alguno. La Fig. 7 muestra que los créditos otorgados a clientes que ya cargaban un saldo en mora en otra entidad incumplen al 36,4 % frente a 4,6 % para el resto, un levantamiento de

7,7 veces la tasa de la cartera (prueba exacta de Fisher, $p = 2,2 \times 10^{-13}$). La información está en el archivo de DataCrédito Experian en el momento de la solicitud. Es decir como baseline, podemos decir que cualquier modelo debería ser capaz de separar a los clientes que ya tienen mora en otra entidad, y que si no lo hace, es un modelo que no esta aprovechando la información disponible.

La regla es barata de aplicar: el grupo marcado es el 0,51 % de la cartera y concentra el 3,91 % de todos los incumplimientos. Su rareza, sin embargo, hay que leerla bien. Bajo la ley colombiana la información negativa de DataCrédito




Figura 7. Tasa de incumplimiento según si el cliente ya cargaba un saldo en mora en otra entidad al momento de la solicitud.

Experian permanece por el doble del tiempo de mora, con tope de cuatro años [13], así que un cliente con mora en el archivo sigue siendo visible durante mucho tiempo. Una tasa de 0,51 % no es entonces evidencia de una población de solicitantes limpia, sino potencial evidencia de que el originador ya filtra por este campo, y los 55 créditos que pasaron son excepciones a una política existente, que es precisamente la razón por la cual incumplen al 36,4 %.

La mora mediana entre esos 55 créditos es de 236.000 pesos, un vencido genuino y no un residuo de redondeo. Eso solo se hizo visible tras la corrección de unidades de la Sección VI; antes de ella, la misma cantidad se leía como 236 pesos y parecía ruido despreciable.

VII-B. Intensidad de consulta

La señal continua más útil es una variable construida. Se define la intensidad de consulta como $huella_consulta / (cant_creditosvigentes + 1)$, es decir, consultas a DataCrédito Experian por cuenta efectivamente abierta. La Fig. 8 muestra la tasa de incumplimiento por decil de esta razón: los dos deciles más altos incumplen al 7,8 % frente a 2,8 % en los tres más bajos, un factor de 2,8, con $\rho = -0,077$ contra el objetivo ($p = 1,8 \times 10^{-15}$).

La variable se lee de forma natural en términos de negocio: un cliente que genera consultas que no se están convirtiendo en aprobaciones es un cliente al que le están negando crédito en otra parte. Además es aditiva y no redundante respecto al score de DataCrédito Experian, y la confirmación externa más fuerte de esto viene de DataCrédito Experian. Ellos afirman de forma explícita que las huellas de consulta no entran en su score, y señala en el mismo documento que varias consultas por parte de distintas compañías en una ventana corta plantean la pregunta de por qué le han negado crédito al cliente [6], [14]. Si las consultas no entran en el score, entonces esta variable carga información que el score no puede contener, y los datos coinciden: ambas correlacionan apenas en $\rho = -0,18$.

VIII. VARIABLES CALCULADAS

Ninguna variable individual es fuerte una vez retirado puntaje; la mejor correlación de rangos con el objetivo es $|\rho| \approx 0,11$. La pregunta es entonces si varias señales débiles se combinan en algo útil.

Se convirtieron a percentiles cuatro señales que no presentaban fugas de datos y se promediaron con pesos iguales: intensidad de consulta, score de DataCrédito Experian bajo, ingreso no corroborado por DataCrédito Experian y mora en el archivo. La Fig. 9 muestra la separación resultante, desde 2,5 % de incumplimiento en el decil más seguro hasta 11,9 % en el más riesgoso, más del doble de la tasa de la cartera. Cada cliente se puntúa con las señales que efectivamente tiene: rellenar las faltantes con un valor neutro habría sido una imputación, y habría afectado a 2.948 de las 10.763 filas.

La Fig. 10 expresa el mismo resultado como una cantidad operativa. Ordenando las solicitudes de peor a mejor banda, una cola de revisión manual que contenga 2.153 de las 10.763 solicitudes alcanzaría el 38 % de todos los incumplimientos, aproximadamente el doble de lo que lograría una revisión aleatoria; extendiendo la cola a 4.305 solicitudes se llega al 63 %. El eje horizontal es deliberadamente un conteo de créditos y no una proporción, porque una cola de revisión se dota en expedientes por semana: 2.153 solicitudes repartidas en dieciocho meses son unas 29 semanales, que es una pregunta de capacidad que un equipo de operaciones puede responder.

IX. LIMITACIONES

Población. El cliente mediano de esta cartera tiene cinco obligaciones abiertas frente a dos o menos en el 62 % de la población de DataCrédito Experian en Colombia, y la mediana del score de DataCrédito Experian es 792. El dataset entonces, se trata de un segmento pre-filtrado y con amplia experiencia crediticia, y la debilidad de las señales que sobreviven podría ser en parte consecuencia de ese filtro y no una propiedad de las variables en una muestra representativa de solicitantes.

Sectores de DataCrédito Experian incompletos. Las tres columnas de conteo por sector suman menos que el conteo total de cuentas en el 71 % de las filas, con un faltante mediano de dos cuentas, y nunca lo exceden. DataCrédito compila obligaciones de los sectores financiero, real, cooperativo y de telecomunicaciones, con fintech reportado ahora junto a ellos [10], así que la columna ausente es potencialmente el sector de telecomunicaciones y fintech y no un error de reporte. Los datos respaldan esa lectura: los clientes con faltante incumplen al 4,5 % frente a 5,4 % de aquellos sin faltante, lo que convierte a una cuenta no financiera no reportada en una señal levemente positiva, tal como cabría esperar de un cliente con un contrato de telefonía pospago al día.

X. CONCLUSIONES

El hallazgo dominante de este análisis es negativo. La columna más predictiva del extracto no se puede usar, y la evidencia es inequívoca: un corredor vacío separa las clases




Figura 8. Tasa de incumplimiento por decil de intensidad de consulta, definida como consultas a DataCrédito Experian por cuenta abierta.




Figura 9. Tasa de incumplimiento por banda de riesgo combinada, usando cuatro señales sin fuga convertidas a percentiles y promediadas con pesos iguales.

y el contexto regulatorio explica con precisión cómo llega a existir una columna así.

El segundo hallazgo es que una columna no significaba lo que decía su nombre, y que ese error era invisible a las verificaciones convencionales de calidad de datos. No produjo valores faltantes ni violaciones de rango, y se detectó únicamente al preguntarse si las magnitudes eran plausibles para el dominio.

El tercer hallazgo es que una vez retirada la columna con fuga, ninguna variable individual separa con fuerza a los clientes que incumplen, pero cuatro señales débiles y libres de fuga combinadas producen una banda con más del doble de la

tasa de incumplimiento de la cartera, y una cola de revisión de 2.153 solicitudes alcanzaría el 38 % de los incumplimientos.

Para ese trabajo de modelado, tres restricciones se siguen directamente del análisis. La variable objetivo está desbalanceada con 4,75 % de positivos, de modo que deben preferirse métricas basadas en precisión y exhaustividad sobre las basadas en ROC [15], y la exactitud simple carece de sentido porque predecir la clase mayoritaria ya acierta el 95,25 %. La partición debe hacerse por fecha de desembolso y no de forma aleatoria. Y `puntaje`, junto con todo lo derivado de ella, debe excluirse, y la exclusión debe verificarse mediante aserción en lugar de suponerse.




Figura 10. Porcentaje de incumplimientos alcanzados según el número de solicitudes enviadas a revisión manual, comparando una cola ordenada por banda de riesgo combinada contra una revisión aleatoria.

Quedan cuatro preguntas que solo el negocio puede responder: si puntaje es en efecto un score de comportamiento y si existe en su lugar un score de originación; cómo se define Pago_atiempo y cuándo queda fijo; qué representa el 23 % del capital que las cuotas contratadas nunca amortizan; y si el sistema origen puede entregar el cuarto sector de DataCrédito Experian que falta.

REFERENCIAS

- [1] D. J. Hand y W. E. Henley, "Statistical Classification Methods in Consumer Credit Scoring: A Review," *Journal of the Royal Statistical Society: Series A*, vol. 160, no. 3, pp. 523–541, 1997.
- [2] L. C. Thomas, "A survey of credit and behavioural scoring: forecasting financial risk of lending to consumers," *International Journal of Forecasting*, vol. 16, no. 2, pp. 149–172, 2000.
- [3] S. Kaufman, S. Rosset y C. Perlich, "Leakage in Data Mining: Formulation, Detection, and Avoidance," en *Proc. 17th ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD)*, 2011, pp. 556–563.
- [4] Asobancaria, "Uso de información alternativa para fortalecer los modelos de originación," *Semana Económica*, 2022. [En línea]. Disponible: <https://www.asobancaria.com/ws/semanas-economicas/1346-BE.pdf>
- [5] Departamento Nacional de Planeación, "Modelos de calificación crediticia con información alternativa," Bogotá, Colombia. [En línea]. Disponible: <https://colaboracion.dnp.gov.co/CDT/Prensa/Publicaciones/modelos-de-calificacion-credicia-con-informacion-alternativa.pdf>
- [6] DataCrédito Experian, "¿Cómo funciona el puntaje de DataCrédito?" [En línea]. Disponible: <https://www.datacredito.com.co/blogs/datablog/como-funciona-el-puntaje-de-datacredito/>
- [7] C. Spearman, "The Proof and Measurement of Association between Two Things," *The American Journal of Psychology*, vol. 15, no. 1, pp. 72–101, 1904.
- [8] Actualícese, "Créditos de consumo de bajo monto: interés bancario corriente y tasa de usura," 2026. [En línea]. Disponible: <https://actualicese.com/creditos-de-consumo-de-bajo-monto-interes-bancario-y-tasa-de-usura-entre-1-y-el-31-de-enero-de-2026/>
- [9] Ciclo de Riesgo, "Indicador de calidad de cartera por mora," 2025. [En línea]. Disponible: <https://cicloderiesgo.com/latam/en-43-cerro-el-indicador-de-calidad-de-cartera-por-mora-en-julio-colombia-tendencia-mejorando>
- [10] DataCrédito Experian, "Newsletter 35: Inclusión crediticia." [En línea]. Disponible: https://www.datacredito.com.co/content/dam/marketing/latam/colombia/co/assets/NL35_INCLUSION_CREDITICIA.pdf
- [11] Buk, "Salario mínimo 2026 en Colombia." [En línea]. Disponible: <https://www.buk.co/blog/salario-minimo-2026-en-colombia>
- [12] Bancolombia, "¿Cómo calcular la capacidad de endeudamiento?" [En línea]. Disponible: <https://blog.bancolombia.com/educacion-financiera/como-calcular-la-capacidad-de-endeudamiento/>
- [13] Congreso de Colombia, "Ley 2157 de 2021 (Ley de Borrón y Cuenta Nueva)," 2021. [En línea]. Disponible: <https://www.affirmalegal.com/blog/ley-de-borron-y-cuenta-nueva-ley-2157-de-2021/>
- [14] Portafolio, "DataCrédito: ¿le puede afectar su puntaje si realiza alguna consulta?" [En línea]. Disponible: <https://www.portafolio.co/mis-finanzas/datacredito-le-puede-afectar-su-puntaje-si-realiza-alguna-consulta-578300>
- [15] T. Saito y M. Rehmsmeier, "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets," *PLoS ONE*, vol. 10, no. 3, e0118432, 2015.